

Итоговый аудит трёх реализаций

Я распаковал архив, проверил структуру кода, выходные .npz/.json/.csv/.obj, сопоставил числовые массивы, просмотрел кропы, маски и UV-текстуры, запустил доступные тесты.

В архиве оказалось по три примера, а не по два:

1999_01_11;

1999_08_16_2;

1999_10_01.

Я использовал все три.

Главное предварительное наблюдение

Исходная реконструкция 3DDFA_V3 у всех разработчиков фактически одна и та же:

object_mesh совпадает до машинного нуля;

alpha_id совпадает до машинного нуля;

у app4 и app5 совпадает identity-only mesh;

исходные фотографии и UV-текстуры имеют одинаковые хэши;

поза и параметры нормализации идентичны.

То есть разработчики не получили три разных 3D-реконструкции. Они по-разному:

организовали сохранение данных;

рассчитали видимость;

разделили identity/expression;

построили Stage 2;

реализовали калибровку и интерпретацию.

Поэтому оценка отражает прежде всего качество системы

вокруг 3DDFA_V3, а не качество самой нейросетевой реконструкции.

Сводный рейтинг

Категория	Разработчик А — app3	Разработчик В — app4	Разработчик С — app5
---	---:	---:	---:
1. Интеграция 3DDFA_V3	76	86	95
2. Детекция и кроп лица	74	80	91
3. Контроль посадки/ reprojection	55	64	76
4. Работа с разными углами	62	79	89
5. Координатные системы	68	84	94
6. Видимость и окклюзия	35	68	95
7. Силуэт и скрытая сторона	32	62	92
8. Identity/ expression separation	52	93	96
9. Устойчивость к кропу и шуму	45	65	82
10. Локализация различий	58	91	83
11. Кожа и UV	70	79	73
12. Контроль качества изображения	66	82	86
13. Калибровка и неопределённость	49	83	91

14. Воспроизводи мость и тестирование	46	78	97
15. Хронология и корректность интерпретации	55	82	92
Средний балл	56/100	78/100	89/100

Итоговые места

Разработчик С / app5 — 89/100

Разработчик В / app4 — 78/100

Разработчик А / app3 — 56/100

Уверенность рейтинга — средне-высокая для архитектуры и Stage 1, средняя для итоговой аналитической точности: в архиве присутствуют только три из заявленных двадцати обработанных фотографий, а полноценные реальные результаты Stage 2 приложены не для всех версий.

Разработчик А — app3

Общая оценка: 56/100

app3 — функционально богатый, но методологически наиболее рискованный вариант. Он быстро переходит от измерений к категорическим интерпретациям, не имея достаточной проверки базовых допущений.

Сильные стороны

Код компилируется без синтаксических ошибок.

Есть полноценная трёхэтапная структура.

Сохраняются:

сетка из 35 709 вершин;

треугольники;

106/134 landmarks;

параметры позы;

alpha_id и alpha_exp;

UV-текстура;

skin metrics;

показатели качества.

Все проверенные числовые массивы конечны.

Индексы треугольников и размеры массивов корректны.

Есть 20 практически полезных текстурных метрик:

GLCM;

LBP;

Sobel;

морфологический top-hat;

локальная дисперсия;

residual-показатели.

Критическая проблема №1: неверная оценка видимости

В app3 видимость определяется так:

Но используются нормали в object space до применения реального поворота головы.

Результат:

при yaw около -43° app3 считает видимыми 99,25% LDM134;

при yaw около $+30^\circ$ — 100% LDM134;

даже для заметно повернутого лица почти все точки объявляются видимыми.

Это физически неправдоподобно. Значительная часть дальнейшего анализа может сравнивать поверхность, которую камера фактически не наблюдала.

Для контраста app5 после front-facing + renderer visibility оставляет:

около 55% поверхности при yaw -43° ;

около 59% при yaw $+30^\circ$;

около 63% на более фронтальном кадре.

Критическая проблема №2: нет identity-only mesh app3 сохраняет:

alpha_id;

alpha_exp;

полную сетку identity + expression.

Но не создаёт отдельную сетку с нулевым expression-компонентом.

В результате часть так называемых «костных» метрик считается по геометрии, содержащей мимику.

Есть эвристический модуль expression detection, но он не заменяет математическое разделение:

```
[
S_{text{identity}}
=
bar S+B_{text{id}}alpha_{text{id}}
]
и
[
S_{text{full}}
=
S_{text{identity}}+
B_{text{exp}}alpha_{text{exp}}.
```

]

Критическая проблема №3: приблизительная схема landmarks

В geometry_metrics.py прямо указано, что группы landmarks являются приблизительными:

Однако на их основе рассчитываются:

орбиты;

скулы;

нос;

челюсть;

асимметрия;

углы;

зоны.

Это неприемлемо для сильных локальных заключений. Если индексная карта не подтверждена официальной топологией модели, название зоны может не соответствовать реальной анатомической области.

Критическая проблема №4: псевдобайесовский вердикт
Используются фиксированные priors:

и вручную назначенные likelihood:

Эти числа не выведены из представленной контрольной выборки. Следовательно, итоговые вероятности нельзя интерпретировать как статистически калиброванные. Особенно проблематичны автоматические вердикты:

synthetic_substitution;

different_person;

«вероятна синтетическая подмена».

Это противоречит корректной границе интерпретации

фотометрического анализа.
Дополнительные недостатки

Нет unit-тестов.

Нет code/config/model hash.

Нет атомарной публикации результатов.

Нет независимой reprojection QA.

При ошибке обратной проекции маски используется обычный resize 224×224 на весь исходник, что пространственно неверно.

UV сохраняется как beauty-текстура без отдельной observed/original/confidence-маски.

Калибровка использует среднее и стандартное отклонение там, где предпочтительнее median/MAD и bootstrap.

Профили шума строятся попарно внутри bin, но контроль источников и независимости наборов слабее, чем у app5.

Вердикт по app3

Это исследовательский прототип, но не готовый измерительный инструмент. Самые серьёзные риски:

неправильная видимость;

смещение identity и expression;

приблизительные landmarks;

некалиброванные вероятностные вердикты.

Что исправлять первым

Перенести видимость на posed normals.

Добавить renderer occlusion.

Создать identity-only mesh.

Заменить approximate landmark map официальными vertex indices.

Удалить автоматические «silicone/different person» вероятности.

Ввести median/MAD/p95/bootstrap calibration.

Добавить тесты.

Разработчик В — app4

Общая оценка: 78/100

app4 — самый функционально широкий вариант. Он содержит значительно больше аналитических модулей, чем конкуренты, но страдает от сложности, большого числа эвристик и склонности подгонять анализ под заранее собранные «зацепки».

Сильные стороны

**1. Корректное разделение identity и expression
app4 создаёт:**

полный mesh;

identity-only mesh;

полный LDM106/LDM134;

identity-only LDM106/LDM134;

отдельные коэффициенты alpha_id и alpha_exp.

Это фундаментальное улучшение относительно app3.

**2. Исправлена базовая ошибка нормалей
app4 применяет поворот к нормалям:**

Это правильное app3.

**3. Самая широкая локальная аналитика
Реализованы или заявлены:**

dense landmark motion;

mesh zones;

rigid Procrustes;

vertex residuals;

спектральные признаки;

геодезические span;

curvature proxies;

morphology;

alpha_id chronology;

quality gate;

texture ROI;

pair-matched calibration;

cross-bin ограничения;

baseline-return;

временные события.

**По способности выдать конкретные локальные детали app4
занимает первое место.**

4. Хорошая отчётность

Есть:

подробные Markdown/HTML-отчёты;

диагностические JSON;

карты зон;

графики;

описания ограничений;

логи;

режимы запуска.

Главная проблема №1: видимость остаётся частично эвристической

Stage 1 использует front-facing normals, но не полноценную renderer visibility для полного mesh.

Stage 2 дополнительно применяет уав-эвристику:

Это лучше app3, но уступает app5, где сохраняются отдельно:

front-facing visibility;

renderer visibility;

combined visibility;

triangle visibility.

В app4 окклюзия определяется главным образом по заранее прописанным группам LDM, а не по фактическому z-buffer каждой реконструкции.

Главная проблема №2: чрезмерное количество proxy-метрик
В коде много признаков с названиями:

proxy_*;

silicone_proxy;

synthetic_ratio_score;

curvature_proxy;

fallback-зоны;

approximate mappings.

Часть из них полезна как скрининг, но они не должны иметь одинаковый статус с прямыми геометрическими измерениями.

Например, `silicone_texture_proxu` рассчитывается через простые отношения текстурных показателей щёк и орбит. Это не валидированный классификатор силикона.

Главная проблема №3: риск confirmation bias
app4 активно использует заранее заданные:

категории PUT/UDMURT/VAS;

эпохи;

critical dates;

prior clues;

persona posterior;

ожидаемые transition signatures.

Хотя документация пытается отделить prior clues от измерений, архитектура всё равно содержит большое количество путей, где предварительная гипотеза влияет на:

зоны внимания;

вес признаков;

ранжирование;

финальное объяснение.

Для исследовательской системы prior clues допустимы только как очередь перепроверки, но не как компонент вероятности личности.

Главная проблема №4: сложная эвристическая fusion-модель
В app4 есть H0/H1/H2/H_UNCERTAIN, но веса и boosts

многочисленны:

aging boost;

golden boost;

baseline boost;

texture ratio;

persona stress;

silicone score;

cross-center;

quality discount;

corroboration count.

Это создаёт трудную для аудита модель. Формально результат выглядит количественным, но часть коэффициентов задаётся вручную.

Дополнительные ограничения

Только три небольших unit-теста.

11 586 строк кода при слабом test coverage.

В коде обнаружено много proxy/fallback-путей.

Есть фиксированный относительный texture floor 0.12.

В Stage 1 UV сохраняется как beauty-версия.

Полный прогон Stage 2 на реальных 1900 фотографиях не подтверждён.

Документация самооценивает forensic backend в 99%+, что

не подтверждается представленными тестами.

Репозиторий перегружен внутренними аудитами и backlog-файлами, но это не заменяет экспериментальную валидацию.

Вердикт по app4

app4 — самая богатая исследовательская лаборатория, но не самая надёжная production-реализация.

Она лучше всего подходит для:

генерации большого числа кандидатов;

локальных карт различий;

поиска потенциально интересных зон;

визуального расследовательского анализа.

Но перед публикацией выводов требуется отдельный строгий слой, который отключит:

persona priors;

silicone scoring;

заранее заданные эпохи;

невалидированные проху;

категорические H1/H2-формулировки.

Что исправлять первым

Добавить renderer/z-buffer visibility.

Отделить прямые метрики от проху.

Полностью исключить persona priors из расчёта.

Заменить эвристическую fusion-модель калиброванными статусами.

Увеличить test coverage минимум в 5–10 раз.

Валидировать каждый metric family на семи контрольных наборах.

Перейти от beauty UV к observed/original/confidence UV.

Разработчик С — app5

Общая оценка: 89/100

app5 — наиболее инженерно строгая и методологически аккуратная реализация. Она менее функционально широкая, чем app4, но лучше отделяет реальные наблюдения от предсказаний модели.

Сильные стороны

1. Лучшая схема данных Stage 1

Сохраняются отдельно:

vertices_object;

vertices_identity_only;

vertices_object_normalized;

vertices_bin_canonical;

vertices_camera;

vertices_image_224;

object и posed normals;

camera parameters;

official landmark vertex indices;

identity-only LDM;

full alpha vector;

alpha_id, alpha_exp, alpha_alb, alpha_sh;

transformation parameters.

Это наиболее прозрачный контракт среди трёх реализаций.

2. Лучшая система видимости

app5 сохраняет:

full_mesh_front_facing;

full_mesh_renderer_visible;

full_mesh_visible = front_facing AND renderer_visible;

LDM visibility;

triangle visibility;

UV observed mask;

UV original mask;

UV confidence.

Это прямо решает обсуждавшуюся проблему:

канонизация удаляет поворот, но не делает скрытую сторону достоверной.

3. Лучшая воспроизводимость

Присутствуют:

source_sha256;

model_hash;

code_hash;

config_hash;

runtime versions;

atomic directory commit;

hash-aware resume;

отдельный validation.json;

manifest status;

строгая проверка shapes и visibility relationships.

4. Лучшее тестирование

Запущено 22 unit-теста, все прошли:

геометрия;

rotation orthonormality;

yaw roundtrip;

visibility packing;

маски;

naming;

atomic storage;

validator;

chronology;

descriptors;

prior clues как coverage, а не ground truth.

У app4 фактически три теста, у app3 — ноль.

5. Наиболее корректная интерпретация

app5 не выдаёт автоматический вердикт:

«двойник»;

«силикон»;

«другой человек».

Вместо этого используются статусы:

within_calibration_noise;

elevated_but_uncertain;

persistent_geometric_change;

expression_dominated;

insufficient_visibility;

insufficient_quality.

Это методологически правильнее.

6. Лучшая калибровка Stage 2

Применяются:

отдельные calibration datasets;

сравнения только внутри pose bin;

median;

MAD;

p95/p99;

matched null по семи наборам;

per-landmark noise;

point coherence;

persistence;

identity-only/full comparison.

Главная проблема №1: Stage 2 пока преимущественно landmark-based

Несмотря на сильное T3, фактический Stage 2 app5 в основном использует:

LDM106;

LDM134;

rigid Kabsch alignment;

13 локальных descriptor families;

alpha_id;

временные статусы.

В текущем коде нет полноценного production-анализа:

dense mesh point-to-plane;

robust ICP;

trimmed vertex residuals;

signed displacement всей поверхности;

анатомических mesh-зон;

геодезических метрик;

спектральных дескрипторов dense mesh.

В этой части app4 функционально сильнее.

Главная проблема №2: alignment по всем видимым landmarks Kabsch alignment выполняется по всем общим видимым точкам:

Нет отдельного стабильного anchor set, выбранного по

repeatability. Это может:

частично «впитать» реальное локальное различие;

сместиться из-за щёк, век или рта;

размыть направление изменения.

Следует совмещать по калиброванным стабильным inner-face anchors, а остатки считать на остальных точках.

Главная проблема №3: кожный анализ пока неполный
app5 лучше всех сохраняет сырьё:

semantic channels;

observed UV;

original UV mask;

confidence.

Но фактического полноценного scikit-image слоя в Stage 2 пока нет. В коде явно присутствует статус pending_texture. То есть app5 создаёт лучшую основу для анализа кожи, но ещё не реализует:

LBP по ROI;

GLCM;

Gabor;

ridge/skeleton wrinkle analysis;

temporal skin graph;

Skan.

По фактической полноте кожного анализа app4 пока впереди.

Главная проблема №4: reprojection QA показывает нули

Во всех трёх app5-примерах:

Это не может служить независимой оценкой точности посадки модели на фотографию. Скорее всего, сравниваются две величины, полученные из одной и той же проекции.

Нужен независимый контроль:

2D detector landmarks;

semantic edge alignment;

silhouette IoU;

reprojection относительно независимой разметки.

Дополнительные вопросы

uv_observed_coverage во всех трёх примерах одинаков: 0.796956.

uv_observed_mask и uv_is_original_mask полностью совпадают.

Это может быть особенностью фиксированной UV-топологии, но требует проверки: observed coverage должно реагировать на ракурс и окклюзию.

Нет crop-jitter ensemble.

Нет multi-resolution stability test.

Хронологический модуль использует несколько фиксированных порогов вроде $p95\ z \geq 4.5$; они должны проходить отдельную оценку false-positive rate.

Зоны Stage 2 являются координатной сеткой 3×3, а не анатомическими областями. Это честно указано, но ограничивает объяснимость.

Вердикт по app5

app5 — лучший фундамент для production-системы:

наиболее достоверная видимость;

наиболее полный контракт данных;

лучший контроль сохранения;

лучшие тесты;

минимальный confirmation bias;

самая корректная терминология результатов.

Но до уровня 95+ не хватает:

dense mesh analysis;

устойчивого anchor alignment;

реального skin/scikit-image/Skan слоя;

независимого reprojection QA;

crop/scale sensitivity ensemble;

полного прогона Stage 2 на реальных данных.

Сравнение фактических выходов

Кропы

app3 и app4 используют практически идентичные кропы.

app5 использует другой способ построения кропа по проекции LDM.

Кроп app5 чаще содержит больше контекста сверху и по бокам.

Для общего UI это хорошо, но для skin ROI всё равно нужен отдельный нормализованный патч.

Маски

app3/app4 используют одинаковые маски.

app5 формирует маску из восьми semantic channels и сохраняет каналы отдельно.

app5 лучше для последующего исключения глаз, бровей и губ.

app3/app4 не позволяют так же полно повторно пересобирать политику маски без нового inference.

UV

Сами uv_texture.png у всех трёх версий идентичны. Различие в том, что:

app3/app4 сохраняют главным образом beauty UV;

app5 дополнительно сохраняет confidence и observed/original masks. Поэтому визуально UV одинаковые, но аналитический контракт app5 существенно лучше.

Какой вариант выбирать

Если нужна база для серьёзной системы

Выбирать app5.

Причины:

правильная видимость;

identity-only данные;

прозрачные пространства координат;

семантические каналы;

валидация;

тесты;

отсутствие автоматических обвинительных вердиктов.

Если нужны максимально разнообразные экспериментальные метрики

Из app4 стоит перенести в app5:

mesh zone residuals;

spectral features;

geodesic spans;

curvature;

локальные signed displacement maps;

расширенный HTML-репорт.
Но переносить следует **без**:

persona priors;

заранее заданных эпох;

silicone probabilities;

heuristic Bayesian fusion;

предварительно назначенных идентичностей.

Что не стоит брать из app3

Не следует переносить:

текущую visibility;

approximate landmark groups;

фиксированные $H_0/H_1/H_2$ likelihood;

автоматические verdict;

«silicone probability»;

полный resize mask fallback.

Оптимальная итоговая архитектура

Лучший путь — не выбирать реализацию целиком, а сделать:

Stage 1 app5 + часть геометрических модулей app4 + принцип интерпретации app5.

То есть:

Сырьё, visibility, UV confidence, identity-only и validator — из app5.

Dense mesh, point-to-plane, geodesic, spectral и локальные карты — адаптировать из app4.

Калибровка median/MAD/p95 по семи наборам — app5.

Prior clues использовать только как список дат для перепроверки.

Итоговые статусы — без автоматического «двойник/маска/операция».

Кожный слой добавить как отдельный канал:

observed UV;

ROI;

scikit-image;

ridge detection;

skeletonization;

Skan;

temporal branch matching.

Финальная оценка потенциала после объединения

app3 в текущем виде: **56/100**;

app4 в текущем виде: **78/100**;

app5 в текущем виде: **89/100**;

app5 + проверенные dense-mesh модули app4 + skin/Skan: потенциально

94–96/100 после реальной калибровки и полного тестового прогона.

Самооценки 97–99% внутри документации разработчиков я бы пока не принимал: представленных данных достаточно для сильного инженерного аудита, но недостаточно для подтверждения forensic-точности такого уровня.

продолжай анализ и сравни 3 версии по топ 50 метрикам

10:26 PM

Сравнение трёх версий по 50 техническим метрикам

Ниже — более гранулярный аудит. Я разделил систему на десять контуров по пять метрик.

Шкала:

90–100 — сильная реализация, пригодная как production-фундамент;

75–89 — хорошо, но есть существенные ограничения;

60–74 — рабочий прототип;

40–59 — частичная или эвристическая реализация;

0–39 — отсутствует либо методологически ненадёжно.

Обозначения:

A — app3

B — app4

C — app5

Баллы относятся к реализации функции, а не к вероятности правильного определения личности.

1. Ядро 3DDFA_V3

№	Метрика	A	B	C	Лидер
---	---	---	---	---	---
1	Один inference на фотографию	45	45	98	C
2	Полнота сохранения параметров модели	75	88	98	C
3	Identity-only геометрия	30	95	98	C

4	Официальная топология и индексы	75	88	98	C
5	Числовая целостность артефактов	95	96	97	C
	Среднее по разделу	64,0	82,4	97,8	C

Анализ

app3 и **app4** выполняют лишнюю работу: отдельно вызывают reconstruction path и затем получают дополнительные выходы через другой путь модели. Это увеличивает вероятность:

различий между проходами;

лишнего времени;

несогласованности параметров;

неочевидного состояния модели.

app5 делает один inference и из него формирует все представления. Identity-only geometry у app3 фактически отсутствует. Наличие alpha_id ещё не означает, что геометрические метрики считаются без expression-компонента.

2. Поза и координатные системы

№	Метрика	A	B	C	Лидер
---	---	---	---	---	---
6	Явное описание пространств координат	65	85	98	C
7	Извлечение yaw/pitch/roll	85	88	92	C

8	Контракт канонизации	65	82	94	C
9	Политика сравнения внутри pose bin	75	90	98	C
10	Защита от cross-pose leakage	55	78	90	C
	Среднее по разделу	69,0	84,6	94,4	C

Анализ

app5 лучше всего разделяет:

object space;

identity-only object space;

normalized object space;

pose-bin canonical space;

camera space;

image-224 space.

Но даже app5 не «восстанавливает» скрытую сторону. Канонизация только убирает поворот координат. Достоверность по-прежнему должна задаваться visibility/confidence.

app4 использует хорошие pose-bin механизмы, но часть Stage 2 зависит от эвристических правил. app3 формально имеет канонические представления, однако ошибочная visibility делает их применение рискованным.

3. Visibility и self-occlusion

№	Метрика	A	B	C	Лидер
---:	---	---:	---:	---:	---

11	Видимость по повернутым нормальям	25	90	98	C
12	Renderer/z-buffer visibility	10	25	98	C
13	Пересечение видимости пары	40	75	97	C
14	Силуэт и самоперекрывание	20	60	92	C
15	Triangle/UV visibility	15	30	97	C
	Среднее по разделу	22,0	56,0	96,4	C

Почему app3 получил 22/100

Это главный дефект app3. Видимость считается по object-space normals до применения поворота головы. Из-за этого при yaw около -43° система объявляет видимыми приблизительно 99% landmarks.

Это влияет не на одну метрику, а сразу на весь downstream:

геометрические расстояния;

асимметрию;

локальные зоны;

UV;

хронологию;

Bayesian evidence.

app4

app4 исправляет направление нормалей, но не реализует полноценную renderer visibility для каждой вершины. Часть окклюзии определяется через yaw и заранее заданные списки landmarks.

app5

app5 правильно разделяет:

front-facing;

renderer-visible;

combined-visible;

triangle visibility;

UV observation.

Это наиболее важное преимущество app5.

4. Кроп, маски и UV

№	Метрика	A	B	C	Лидер
---	---	---	---	---	---
16	Корректность кропа	72	80	92	C
17	Семантические маски	75	82	98	C
18	Отсутствие пространственно неверного fallback	35	60	98	C
19	Observed/original UV masks	15	20	96	C
20	UV confidence map	10	20	94	C
	Среднее по разделу	41,4	52,4	95,6	C

Критический нюанс app5

Хотя контракт app5 намного сильнее, фактический observed_coverage во всех трёх примерах одинаков:

Также uv_observed_mask и uv_is_original совпадают между примерами побитно.

Это означает, что UV coverage пока в значительной степени определяется фиксированной UV-топологией. Pose-specific наблюдаемость проявляется больше через uv_confidence, чем через форму observed-маски. Следовательно, 94–96 баллов относятся к **структуре данных**, но сам алгоритм построения UV evidence ещё следует усилить:

```
[
C_{UV}(u,v)=
V_{\text{renderer}}
\cdot
\max(0,ncdot v)
\cdot
Q_{\text{resolution}}
\cdot
Q_{\text{projection}}.
]
```

5. Качество изображения и uncertainty

№	Метрика	A	B	C	Лидер
---	---	---	---	---	---
21	Измерение резкости и шума	80	85	88	C
22	Blur/JPEG diagnostics	78	85	85	B/C
23	Coverage и effective resolution	70	78	88	C
24	Применение quality gate в Stage 2	55	88	55	B
25	Региональная неопределённость	35	65	75	C
	Среднее по разделу	63,6	80,2	78,2	B

Почему app4 обогнал app5

app5 хорошо рассчитывает и сохраняет качество Stage 1, но фактический

Stage 2 не полностью использует эти параметры при сравнении пары.
То есть данные есть, однако нет достаточно строгого правила вроде:

```
[
w_{i,A,B}
=
min(
q_{i,A},
q_{i,B},
v_{i,A},
v_{i,B}
).
]
```

app4 активнее применяет downstream quality gate:

пропускает слабые пары;

понижает вес;

маркирует низкое качество;

ограничивает часть выводов.

Для app5 это один из самых простых способов быстро повысить реальную надёжность.

6. Геометрическое сравнение

№	Метрика	A	B	C	Лидер
---	---	---	---	---	---
26	Устойчивое совмещение пары	55	78	82	C
27	Совмещение по стабильным anchors	30	55	40	B
28	Dense-mesh comparison	50	95	35	B

29	Signed local displacement	45	88	80	B
30	Geodesic/spectral/curvature	40	95	75	B
	Среднее по разделу	44,0	82,2	62,4	B

Здесь app4 — явный лидер

app4 содержит наиболее широкий набор геометрических представлений:

vertex residuals;

mesh zones;

curvature;

morphology;

spectral signatures;

geodesic spans;

signed displacements;

локальные карты.

app5 в фактическом Stage 2 преимущественно сравнивает LDM106/LDM134. Это хороший baseline, но не полный dense 3D-анализ.

Ограничение app5 alignment

app5 выполняет Kabsch alignment по всем общим видимым landmarks. Это лучше отсутствия alignment, но не оптимально.

Нужно разделить точки на:

anchor set — стабильные внутренние области;

measurement set — точки, на которых измеряется изменение.

Иначе мягкие ткани и потенциально изменившиеся зоны участвуют в самом совмещении и частично поглощают измеряемый сигнал.

Какой alignment нужен

Начальная посадка по inner-face anchors.

Robust Kabsch или trimmed Procrustes.

Исключение верхних 10–20% residuals.

Повторное совмещение.

Dense point-to-plane residual.

Сохранение signed displacement относительно нормалей.

7. Skin texture и морщины

№	Метрика	A	B	C	Лидер
---	---	---	---	---	---
31	Разнообразие skin features	85	88	10	B
32	Региональный texture analysis	55	85	15	B
33	Различение ретуши/ артефактов	60	75	35	B
34	Граф морщин и Skan	0	5	0	—
35	Разделение geometry и texture	55	78	95	C
	Среднее по разделу	51,0	66,2	31,0	B

Почему app5 получил только 31/100

app5 сохраняет лучшие исходные данные для кожи, но сам skin-analysis ещё не реализован. В Stage 2 присутствует состояние pending_texture. Это важное различие:

готовность данных — высокая;

фактический анализ кожи — низкий.

app3

app3 имеет богатый набор scikit-image признаков:

GLCM;

LBP;

Sobel;

local variance;

top-hat;

residuals.

Но их доказательная сила снижается из-за:

недостаточной visibility;

beauty UV;

отсутствия observed confidence;

потенциально неверных fallback-масок.

app4

app4 имеет наиболее полный рабочий texture layer, но некоторые признаки получили слишком сильные названия:

silicone_proxy;

synthetic_ratio;

retouch_score.

Они могут использоваться как **quality/artifact indicators**, но не как диагностика материала или вмешательства.

Skan

Полноценного анализа графа морщин нет ни в одной версии.

Не реализованы:

skeleton graph;

branch length;

junction count;

endpoint persistence;

graph matching между датами;

стабильность ориентации ветвей;

исчезновение и повторное появление одной морщины.

8. Калибровка и статистика

№	Метрика	A	B	C	Лидер
---	---	---	---	---	---
36	Same-person calibration	70	85	94	C
37	Pose-bin-specific calibration	78	90	98	C
38	Робастные оценки шума	55	82	96	C
39	Matched null и семь наборов	60	90	98	C
40	Bootstrap/FPR/OOD-контроль	20	50	40	B
	Среднее по разделу	56,6	79,4	85,2	C

app5

Сильные элементы:

median/MAD;

p95/p99;

отдельные pose bins;

контрольные same-person datasets;

prior clues только как coverage;

независимые calibration inputs.

Что отсутствует у всех

Ни одна версия пока не продемонстрировала полноценную оценку:

false-positive rate;

false-negative rate;

confidence interval для порога;

out-of-distribution detection;

bootstrap stability;

sensitivity к составу калибровочного набора;

leave-one-camera-out validation;

leave-one-year-out validation.

Порог вроде $p95\ z \geq 4.5$ сам по себе не становится научно обоснованным только потому, что выражен через z-score.

9. Хронологический анализ

№	Метрика	A	B	C	Лидер
---	---	---	---	---	---
41	Парсинг дат и последовательности	75	85	98	C
42	Adjacent/baseline/rolling references	75	90	92	C
43	Нормализация по временному интервалу	65	85	92	C

44	Persistence и reversion	75	92	90	B
45	Cross-bin corroboration	65	90	70	B
	Среднее по разделу	71,0	88,4	88,4	B/C

app4

app4 лучше реализует разнообразные хронологические режимы:

adjacent;

baseline;

return to baseline;

эпохи;

локальные события;

persistence;

reversion;

cross-bin corroboration.

Проблема — заранее заданные эпохи и persona-related clues могут создавать confirmation bias.

app5

app5 методологически чище, но осторожнее и уже:

хорошо работает внутри pose bin;

не смешивает непохожие ракурсы;

корректно маркирует недостаточную видимость;

не делает категорических выводов.

Однако подтверждение одного изменения в разных pose bins ещё недостаточно развито.

Правильный принцип

Хронологический сигнал должен удовлетворять одновременно:

появляется после определённой даты;

наблюдается минимум на нескольких фотографиях;

повторяется в разных источниках;

остаётся локально согласованным;

подтверждается в двух pose bins;

не исчезает после смены света или оптики;

сильнее same-person null distribution.

10. Инженерия и интерпретация

№	Метрика	A	B	C	Лидер
---	---	---	---	---	---
46	Автоматические тесты	20	55	98	C
47	Atomic commit/ resume/ validator	55	78	98	C
48	Хэши и provenance	50	72	99	C
49	Отчётность и объяснимость	90	96	90	B
50	Осторожная интерпретация	25	55	99	C
	Среднее по разделу	48,0	71,2	96,8	C

Тестирование

Фактический результат:

app3 — unit-тесты отсутствуют;

app4 — три небольших теста;

app5 — 22 теста, все прошли.

Интерпретация

app3 получает только 25 баллов из-за автоматических заключений:

different_person;

synthetic_substitution;

silicone.

app4 формально осторожнее, но содержит:

persona posterior;

prior clues;

predefined eras;

silicone proxy;

большое количество эвристических boosts.

app5 лучше всех отделяет:

наблюдение;

качество;

калибровочное отклонение;

persistence;

интерпретацию.

Итог по всем 50 метрикам

Версия	Средний балл	Победы в разделах	Характер системы
---	---:	---:	---

app3	53,1/100	0 из 10	Функциональный, но методологически опасный прототип
app4	74,3/100	3 из 10, включая ничью	Самая широкая аналитическая лаборатория
app5	82,6/100	8 из 10, включая ничью	Лучший инженерный и научно-осторожный фундамент

Почему оценки ниже предыдущих 56/78/89

Это не пересмотр аудита, а другая система агрегирования.

Предыдущая таблица из 15 категорий оценивала крупные способности системы. В таблице из 50 метрик одинаковый вес получили отдельные отсутствующие функции:

Skan;

skin texture;

dense mesh;

renderer visibility;

UV confidence;

bootstrap/FPR;

stable-anchor alignment.

Поэтому:

app5 сильнее штрафуются за незавершённый texture layer и dense Stage 2;

app4 — за отсутствие renderer/UV visibility и слабое тестирование;

app3 — за ошибки visibility и отсутствие engineering safeguards.

Где каждая версия действительно лучше

app3

Лучшие стороны:

базовая числовая целостность;

готовый набор scikit-image признаков;

информативные отчёты;

извлечение позы;

относительно простой pipeline.

Но texture-функции app3 работают поверх недостаточно надёжной системы наблюдаемости.

app4

Лучшие стороны:

dense mesh analysis;

геодезические признаки;

спектральные признаки;

curvature и morphology;

локализация различий;

хронологические режимы;

региональная texture analytics;

визуальная объяснимость.

Главный риск app4 — смешение хороших измерений с эвристическими proxy и prior-driven inference.

app5

Лучшие стороны:

один inference;

identity-only geometry;

строгие пространства координат;

renderer visibility;

UV confidence;

официальный topology contract;

robust calibration;

тестирование;

воспроизводимость;

осторожная интерпретация.

Главный пробел — отсутствуют полноценные dense geometry и skin texture stages.

Рекомендуемая сборка версии 4

Оптимальный вариант:

Основа из app5

Оставить:

single inference;

все координатные представления;

identity-only mesh;

renderer visibility;

combined visibility;

triangle visibility;

semantic channels;

UV observed/original/confidence;

hashes;

atomic commit;

validator;

cautious statuses.

Перенести из app4

После отдельной проверки перенести:

dense mesh zones;

signed normal displacement;

geodesic spans;

spectral signatures;

curvature descriptors;

morphology;

baseline-return;

cross-bin corroboration;

HTML visualizations.

Не переносить:

persona posterior;

silicone probability;

predetermined identity eras;

heuristic Bayesian boosts;

prior-driven weighting.

Добавить с нуля

Stable anchor set.

Trimmed robust Kabsch.

Dense point-to-plane ICP.

Независимую 2D reprojection QA.

Crop-jitter ensemble.

Реальный UV visibility rasterization.

Multi-scale Gabor/LBP/GLCM.

Ridge detector морщин.

Skeletonization.

Skan graph matching.

Bootstrap confidence intervals.

OOD detector.

Empirical false-positive rate.

Camera/source matching.

Human-review protocol.

После этого объединённая версия может претендовать на **94–96/100 по архитектуре**, но только после валидации на полном датасете, а не на трёх приложенных примерах.

выполни анализ по седующим 60 метрикам

10:29 PM

Дополнительный аудит: метрики 51–110

Это **следующие 60 метрик**, не повторяющие предыдущие 50. Теперь общий чек-лист охватывает **110 параметров**.

Обозначения:

A — app3

B — app4

C — app5

Баллы отражают полноту и методологическую надёжность реализации, а не процент точности определения личности.

11. Входные данные и происхождение фотографий

№	Метрика	A	B	C	Лидер
---:	---	---:	---:	---:	---

51	Проверка EXIF и подлинности даты	45	65	72	C
52	Строгая схема имён и идентификаторов	80	88	98	C
53	Хэширование исходных изображений	60	72	99	C
54	Обнаружение дубликатов	45	65	80	C
55	Error manifest и безопасный перезапуск	70	82	97	C
	Среднее	60,0	74,4	89,2	C

Вывод

app5 лучше всего обеспечивает техническую идентичность входного файла:

сохраняет source hash;

проверяет результат при resume;

не переиспользует результат после изменения кода, модели или конфигурации;

публикует папку результата атомарно.

Но ни одна версия не подтверждает реальную историческую дату фотографии. Имя файла 1999_01_11 — это метка датасета, а не доказательство даты съёмки.

Для forensic-уровня нужны отдельно:

EXIF;

дата публикации;

источник;

архивная копия страницы;

контроль обратного поиска;

признаки повторной публикации старого кадра.

12. Детекция лица и стабильность кропа

№	Метрика	A	B	C	Лидер
---	---	---	---	---	---
56	Обработка нескольких лиц	55	65	72	C
57	Учёт confidence детектора	65	72	80	C
58	Поля кропа и сохранение контекста	70	78	90	C
59	Прозрачность fallback-процедур	40	65	92	C
60	Повторяемость кропа	50	68	78	C
	Среднее	56,0	69,6	82,4	C

Главный недостаток всех версий

Нет полноценного crop-jitter test:

сместить bbox на $\pm 2\%$, $\pm 4\%$, $\pm 6\%$;

изменить масштаб кропа;

повторить reconstruction;

измерить разброс alpha_id, landmarks и mesh;

понижить confidence нестабильных областей.

Сейчас одиночный удачный кроп может выглядеть как надёжный результат, хотя при смещении рамки на несколько пикселей часть метрик может измениться.

13. Исполнение модели и runtime

№	Метрика	A	B	C	Лидер
---	---	---	---	---	---
61	Переносимость CPU/CUDA/MPS	70	75	85	C
62	Детерминированное исполнение	40	55	85	C
63	Batch throughput	55	65	70	C
64	Изоляция ошибки одного изображения	65	75	95	C
65	Runtime manifest	55	70	98	C
	Среднее	57,0	68,0	86,6	C

Детализация

app5 фиксирует:

версии библиотек;

конфигурацию;

модель;

код;

источник;

результат валидации.

Это позволяет установить, почему два запуска дали разные результаты.

Но даже app5 не демонстрирует полный deterministic protocol:

Также не показано, одинаковы ли результаты на:

CPU;

CUDA;

Apple MPS;

разных версиях PyTorch.

Для forensic pipeline межустройственная погрешность должна измеряться как отдельный null dataset.

14. Целостность 3D-сетки

№	Метрика	A	B	C	Лидер
---:	---	---:	---:	---:	---
66	Проверка shapes массивов	65	75	98	C
67	Валидность triangle indices	80	85	98	C
68	Winding и согласованность нормалей	55	70	92	C
69	Ортонормальность rotation matrix	75	85	98	C
70	Нормализация масштаба	70	82	95	C
	Среднее	69,0	79,4	96,2	C

Фактическая проверка

Во всех трёх приложенных наборах:

float-массивы конечны;

triangle indices находятся в допустимых границах;

UV лежат приблизительно в диапазоне [0.02, 0.98];

rotation matrices ортонормальны;

максимальная ошибка ортонормальности — порядка 1.19×10^{-7} .

Поэтому базовые артефакты не повреждены.

Преимущество app5 заключается не в том, что его mesh «точнее» — mesh совпадает с другими версиями, — а в том, что app5 строже проверяет контракт каждого массива.

15. Landmarks и семантика точек

№	Метрика	A	B	C	Лидер
---	---	---	---	---	---
71	Официальное соответствие landmarks	65	80	98	C
72	Согласованность LDM106 и LDM134	75	85	97	C
73	Видимость каждой landmark	30	72	96	C
74	Confidence каждой landmark	25	50	90	C
75	Исключение expression-sensitive точек	45	78	88	C
	Среднее	48,0	73,0	93,8	C

app3

Наиболее серьёзная проблема — approximate landmark groups. Группа с

названием «орбита» или «скула» не обязательно подтверждена официальной анатомической картой модели.

app4

Улучшает:

identity landmarks;

локальные зоны;

expression checks;

comparison masks.

Но часть зон и индексов всё ещё является прикладной эвристикой.

app5

Лучше связывает landmarks с официальными vertex indices. Однако полноценного отдельного confidence для каждой landmark, основанного на:

resolution;

visibility;

incidence angle;

reprojection residual;

semantic certainty,

ещё нет. Текущая visibility сильнее, чем uncertainty model.

16. Надёжность оценки позы

№	Метрика	A	B	C	Лидер
---:	---	---:	---:	---:	---
76	Согласованность rotation matrix и Euler angles	70	80	95	C

77	Ограниче ние экстрема льного yaw	40	75	92	C
78	Учёт pitch и roll	55	70	85	C
79	Неопреде лённость самой позы	30	55	75	C
80	Расстоян ие между позами пары	70	88	95	C
	Среднее	53,0	73,6	88,4	C

Что ещё требуется

Pose bin не должен быть единственной проверкой. Две фотографии могут попасть в один bin, но отличаться на 10–15 градусов.

Нужен непрерывный показатель:

```
[
D_{text{pose}}=
sqrt{
w_y(Delta yaw)^2+
w_p(Delta pitch)^2+
w_r(Delta roll)^2
}.
]
```

И затем:

жёсткий предел для геометрии;

более строгий предел для текстуры;

отдельная поправка для каждой анатомической зоны.

17. Сложные окклюзии

№	Метрика	A	B	C	Лидер
---:	---	---:	---:	---:	---

81	Очки, волосы, руки и внешние окклюзии	20	35	45	C
82	Depth- buffer occlusion	10	25	98	C
83	Confidenc е при касательн ом угле	20	45	90	C
84	Pairwise visibility intersecti on	35	75	98	C
85	Исключен ие одностор онне видимых зон	30	70	96	C
	Среднее	23,0	50,0	85,4	C

Ограничение renderer visibility

Renderer отвечает на вопрос:

Закрыта ли эта точка другой частью 3D-сетки лица?

Но он не всегда знает, что точку закрывают:

волосы;

оправа очков;

тень;

микрофон;

рука;

головной убор;

посторонний предмет.

Поэтому даже app5 нуждается во внешнем occlusion segmentation.

Важный принцип

Сравнение должно выполняться только на:

[
 $V_{\{AB\}} = V_A \text{ land } V_B \text{ land } S_A \text{ land } S_B$,
]

где:

V — геометрическая видимость;

S — семантическая пригодность пикселя.

18. Происхождение UV-текстуры

№	Метрика	A	B	C	Лидер
---	---	---	---	---	---
86	Обратная трассировка UV → изображение	55	65	92	C
87	Provenance исходного пикселя	35	50	95	C
88	Разделение holes и inpainting	20	35	94	C
89	Нормализация освещения	45	65	45	B
90	Контроль цветового пространства	50	60	70	C
	Среднее	41,0	55,0	79,2	C

Основной вывод

app5 лучше показывает, какие UV-пиксели:

действительно происходят из фотографии;

наблюдались;

имеют confidence;

относятся к исходной текстуре.

Но app5 ещё не имеет готовой photometric normalization.

Для кожи нужны как минимум:

перевод в linear RGB;

контроль gamma;

LAB/YCbCr-разделение;

локальное устранение low-frequency illumination;

исключение specular highlights;

нормализация white balance;

сравнение texture преимущественно в luminance/chrominance residuals.

Без этого свет может менять GLCM/LBP сильнее, чем реальная поверхность кожи.

19. Локальная анатомическая геометрия

№	Метрика	A	B	C	Лидер
---:	---	---:	---:	---:	---
91	Анатомические mesh-зоны	45	90	65	B
92	Лево-правое соответствие	55	85	75	B
93	Симметрия после коррекции позы	50	82	78	B
94	Signed displacement вдоль нормали	40	90	70	B

95	Scale-invariant ratios	65	88	85	B
	Среднее	51,0	87,0	74,6	B

Почему app4 сильнее

app4 лучше всего подготовлен для ответа:

Где именно находится отличие?

Он имеет более богатые механизмы:

mesh zones;

bilateral comparison;

morphology;

signed displacements;

curvature;

spectral/geodesic descriptors.

app5 пока больше ориентирован на landmarks и координатные зоны 3×3.

Это полезно для отладки, но хуже соответствует анатомии.

Что переносить в app5

Из app4 следует перенести:

зону переносицы;

внутренние и внешние орбиты;

скуловые дуги;

верхнюю и нижнюю челюсть;

подбородочный выступ;

лобные дуги;

основание носа;

крылья носа.

Но только после проверки официальных vertex sets.

20. Временная статистика и зависимость источников

№	Метрика	A	B	C	Лидер
---	---	---	---	---	---
96	Агрегация кадров одного дня	40	65	75	C
97	Контроль зависимости источников	35	60	70	C
98	Стратификация по камере и кодеку	40	70	65	B
99	Коррекция множественных проверок	20	45	35	B
100	Формальный changepoint detection	50	80	78	B
	Среднее	37,0	64,0	64,6	C

Почему этот раздел слабый у всех

20 кадров из одной фотосессии не равны 20 независимым наблюдениям. Если фотографии происходят из:

одной видеозаписи;

одного агентства;

одного момента;

одной камеры;

одной JPEG-цепочки,
их нельзя считать независимыми подтверждениями.

Нужна иерархия:

Статистической единицей должен быть преимущественно **event/source**, а

не отдельный файл.

Множественные проверки

Если анализируются:

35 709 вершин;

134 landmarks;

десятки временных интервалов;

множество признаков,
то даже чистый шум создаст экстремальные z-score.
Нужны:

Benjamini–Hochberg FDR;

cluster-level inference;

permutation maximum statistic;

persistence threshold;

минимум независимых источников.

21. Объяснимость и доказательная цепочка

№	Метрика	A	B	C	Лидер
---	---	---	---	---	---
101	Provenance каждой метрики	55	75	95	C
102	Локальные heatmaps	60	95	85	B
103	Статус достаточности evidence	40	78	98	C
104	Учёт альтернативных причин	55	80	95	C

105	Полный audit trail	60	82	98	C
	Среднее	54,0	82,0	94,2	C

app4

Лучше всех визуализирует:

локальные зоны;

displacement;

временные изменения;

рейтинги признаков;

карты различий.

app5

Лучше отвечает на вопросы:

какой файл использовался;

какой код использовался;

какая конфигурация;

какая модель;

какие зоны были видимы;

достаточно ли данных;

какой статус допустим.

app3

Отчётность визуально сильная, но вывод иногда категоричнее, чем позволяет доказательная база.

22. Воспроизводимость и упаковка проекта

№	Метрика	A	B	C	Лидер
---	---	---	---	---	---
106	Фиксация зависимостей	55	65	85	C

107	Фиксация версии модели	65	75	98	C
108	Снимок конфигурации	60	75	99	C
109	Проверка целостности артефактов	55	78	99	C
110	Чистота и переносимость пакета	50	65	92	C
	Среднее	57,0	71,6	94,6	C

app5

Наиболее близок к воспроизводимому исследовательскому продукту:

code hash;

model hash;

config hash;

source hash;

validator;

manifest;

atomic commit;

hash-aware resume.

app4

Кодовая база богаче, но значительно крупнее:

около 11 586 строк;

большое количество аналитических модулей;

документация, backlog и assessment-файлы;

слабое тестовое покрытие относительно размера.

Это повышает стоимость проверки и риск скрытых взаимодействий между эвристиками.

app3

Проще, но не хватает:

unit-тестов;

строгой фиксации окружения;

полной валидации результата;

защиты от смешения старых и новых артефактов.

Итог по дополнительным 60 метрикам

Версия	Балл по метрикам 51–110	Основное преимущество	Основной недостаток
---	---:	---	---
app3	50,5/100	Простота и базовые texture-функции	Visibility и слабый контроль доказательност и
app4	70,6/100	Dense geometry и локализация	Эвристики, priors и недостаточное тестирование
app5	85,8/100	Visibility, provenance и воспроизводим ость	Неполный dense/texture Stage 2

Объединённый результат по 110 метрикам

Первые 50 и дополнительные 60 имеют разную детализацию, но при равном весе всех 110 показателей получается:

Место	Версия	Первые 50	Следующие 60	Итог 110
---:	---	---:	---:	---:
1	app5	82,6	85,8	84,3/100
2	app4	74,3	70,6	72,3/100
3	app3	53,1	50,5	51,7/100

Формула:

$$[$$

$$\text{Score}_{\{110\}} =$$

$$\text{frac}\{$$

$$50 \cdot \text{Score}_{\{1-50\}} +$$

$$60 \cdot \text{Score}_{\{51-110\}}$$

$$\}_{\{110\}}.$$

$$]$$

Самые важные новые выводы

1. app5 уверенно выигрывает инженерную часть

Особенно по:

provenance;

visibility;

валидации;

hashes;

устойчивости сохранения;

воспроизводимости;

evidence sufficiency.

2. app4 остаётся лучшим в локальной геометрии

app4 сильнее по:

dense mesh;

анатомическим зонам;

signed displacement;

геодезическим и спектральным признакам;

локальным heatmaps;

changepoint analysis.

3. app3 нельзя безопасно использовать без исправления visibility

Ошибка object-space normals делает сомнительными не только visibility-файлы, но и любые последующие метрики, использующие якобы наблюдаемые зоны.

4. Ни одна версия не реализует полноценный анализ морщин

Отсутствуют:

ridge graph;

skeleton;

Skan;

branch correspondence;

temporal persistence;

confidence-weighted wrinkle topology.

5. Ни одна версия пока не доказывает forensic accuracy

Не представлены:

ground-truth benchmark;

полный прогон заявленных 20 результатов;

1900-image validation;

false-positive rate;

внешняя слепая проверка;

межустройственная воспроизводимость;

контроль множественных сравнений.

Окончательная рекомендация после 110 метрик

Наиболее рациональная архитектура:

app5 как ядро и контракт данных + проверенные dense-модули app4 + новый skin/Skan слой.

app3 имеет смысл использовать только как источник отдельных scikit-image идей, но не как основу итогового inference. app4 полезен как библиотека экспериментальных метрик. app5 — наиболее надёжная основа для дальнейшей разработки.

продолжай анализ и сравни 3 версии по реализации исключения шума + интеграции калибровочного датасета с наибольшей эффективностью

Сравнение подавления шума и интеграции калибровочного датасета

Здесь важно различать два вида эффективности:

Статистическая эффективность — насколько хорошо система отделяет устойчивое изменение от ракурса, мимики, света, blur и ошибок реконструкции.

Вычислительная эффективность — сколько повторных inference, попарных сравнений и промежуточных файлов требуется.

Краткий вывод

app3: калибровка присутствует, но ошибочная visibility и неробастные статистические предположения пропускают слишком много шума.

app4: лучше всех подавляет разнообразные виды уже известных шумов, но делает это сложной системой эвристик и дорогих попарных вычислений.

app5: лучший фундамент для эффективной калибровки геометрии — один inference, надёжная visibility, компактные признаки, median/MAD и строгий provenance. Но нужно подключить quality gate и расширить калибровку на dense mesh и texture.

1. Сравнение исключения шума

Источник шума	app3	app4	app5
---	---	---	---
Разница yaw/ pitch/roll	43	76	94
Невидимая сторона лица	20	55	97
Мимика	45	92	95
Нестабильный кроп	45	65	82
Blur, JPEG, низкое разрешение	62	84	75
Свет и цвет для кожи	50	72	35

Выбросы в геометрии	48	80	94
Изменение кода/модели/config	45	70	98
Зависимость от камеры и источника	40	70	65
Множественные статистические проверки	20	45	35
Среднее	41,8	70,9	77,0

app3: почему шум недостаточно подавляется

1. Ошибка visibility

app3 использует object-space normals без реального поворота головы. Поэтому скрытая сторона может попасть в сравнение как достоверное наблюдение.

Никакая последующая калибровка не может полностью исправить это: на вход статистике уже переданы неверные данные.

2. Identity смешивается с expression

Отсутствует полноценный identity-only mesh. Мимическое изменение может интерпретироваться как структурное.

3. Mean/std вместо устойчивой оценки

Для небольших и неоднородных выборок среднее и стандартное отклонение чувствительны к:

единичным плохим реконструкциям;

сильному blur;

неправильному кропу;

экстремальному ракурсу;

выбросам landmarks.

Предпочтительнее:

```
[
z_{text{robust}}=
frac{x-operatorname{median}(X)}
{1.4826cdot MAD(X)+epsilon}.
]
```

4. Фиксированные вероятности

Фиксированные priors и вручную назначенные likelihood не исключают

шум, а только превращают его в формально выглядящую вероятность.

Итог по app3

Использовать калибровочные модули app3 без исправления Stage 1 нельзя. В первую очередь необходимо устранить:

неверную visibility;

смещение identity/expression;

approximate landmarks;

фиксированную Bayesian fusion.

app4: наиболее широкий набор фильтров шума

app4 подавляет больше видов шума, чем остальные версии:

pose-bin comparison;

identity-only mesh;

quality gate;

expression filtering;

same-bin chronology;

pair-matched calibration;

локальные mesh-зоны;

texture-quality indicators;

baseline return;

corroboration;

persistence.

Сильная сторона

app4 лучше всего учитывает, что разные признаки имеют разные источники погрешности:

landmark noise;

mesh noise;

texture noise;

expression noise;

pose noise;

chronology noise.

Главный недостаток

Подавление шума смешано с эвристиками:

фиксированный texture floor;

persona-era logic;

prior clues;

synthetic/silicone proxies;

многочисленные boosts;

fallback-метрики.

Из-за этого сложно определить, уменьшила система шум или просто изменила итоговый score по ручному правилу.

Вычислительная проблема

Многие калибровочные операции строятся через попарные сравнения.

При (N) фотографиях количество пар:

$$P = \frac{N(N-1)}{2}.$$

Для 1900 изображений:

$$P = 1,804,050.$$

Это ещё возможно для компактных landmarks, но дорого для:

полной сетки из 35 709 вершин;

UV-текстур;

спектральных метрик;

множества pose bins;

повторных bootstrap-запусков.

Итог по app4

app4 — лучший источник идей для noise modeling, но его калибровку необходимо упростить и отделить от hypothesis-driven эвристик.

app5: лучший геометрический noise floor

app5 лучше всего исключает геометрический шум до вычисления метрики:

```
[  
M_{AB}  
=  
V_A  
land  
V_B  
land  
F_A  
land  
F_B  
land  
Q_A  
land  
Q_B.  
]  
Где:
```

(V) — renderer visibility;

(F) — front-facing;

(Q) — пригодность точки;

(M_{AB}) — область, реально наблюдаемая на обеих фотографиях.

Сильные стороны

один inference;

identity-only geometry;

front-facing visibility;

renderer visibility;

intersection visibility;

pose bins;

median/MAD;

per-landmark noise;

matched null datasets;

code/model/config hashes;

cautious statuses.

Главный недостаток

Quality Stage 1 ещё недостаточно полно потребляется Stage 2. Система сохраняет показатели качества, но фактическое сравнение не всегда использует их как вес каждой точки.

Правильная схема:

```
[
w_i=
min(
v_{i,A},
v_{i,B},
q_{i,A},
q_{i,B},
r_{i,A},
r_{i,B}
),
]
```

где (r) — локальная эффективная разрешающая способность.

Второй недостаток

Калибровка app5 пока сильнее для LDM106/LDM134, чем для:

dense mesh;

UV texture;

морщин;

ретуши;

освещения.

2. Интеграция калибровочного датасета

Критерий	app3	app4	app5
---	---:	---:	---:

Формальный контракт калибровочных данных	60	88	96
Разделение по pose bins	75	90	98
Разделение по качеству	50	85	55
Per-landmark calibration	60	85	98
Median/MAD и robust statistics	55	82	96
Matched same-person null	60	90	98
Контроль независимости кадров	45	70	80
Вычислительная эффективность	55	50	92
Кэширование и повторное использование	50	70	98
Безопасные статусы вместо вердикта	40	65	95
Bootstrap/FPR validation	20	50	40
OOD/insufficient-data gate	35	75	95
Среднее	50,4	75,0	86,8

Победитель: **app5**

app5 лучше всего подходит для интеграции большого калибровочного датасета, потому что не требует повторного запуска 3DDFA для каждого эксперимента.

Его Stage 1 можно рассматривать как неизменяемый feature store:

После этого можно менять:

pose bins;

статистические пороги;

калибровочные выборки;

дескрипторы;

chronology rules;

без повторной 3D-реконструкции.

3. Как интегрировать калибровочный датасет максимально эффективно

Шаг 1. Не считать все фотографии независимыми

Калибровочный индекс должен иметь структуру:

Это позволяет не принять 30 кадров одной видеозаписи за 30 независимых доказательств.

Шаг 2. Разделить калибровку на три независимых слоя

A. Геометрический null

Использовать:

identity-only mesh;

LDM106/LDM134;

dense mesh;

same-person pairs;

разные даты;

независимые источники;

одинаковые pose bins.

B. Expression null

Сравнивать:

full mesh;

identity-only mesh;

alpha_exp;

рот;

веки;

брови;

щёки.

Цель — определить, какая часть residual объясняется мимикой.

C. Photometric null

Отдельно калибровать:

UV texture;

освещение;

JPEG;

blur;

цветовой баланс;

эффективное разрешение;

ретушь;

source/camera family.

Нельзя объединять геометрический и texture noise в один общий z-score.

Шаг 3. Иерархическая калибровка вместо множества узких bin

Если сделать слишком много bins:

часть ячеек будет почти пустой.

Лучше использовать иерархию:

глобальный same-person null;

pose-bin null;

pose + quality null;

pose + quality + source поправка.

Для редкого bin применяется shrinkage:

[
theta_b^{*}

=

lambda_b theta_b +

(1-lambda_b) theta_{\text{global}},

]

где:

[

$\lambda_b = \frac{n_b}{n_b + k}$.

]

Чем меньше наблюдений в bin, тем сильнее он приближается к глобальной оценке.

Шаг 4. Не строить все (N^2) пары

Для калибровки не нужны все возможные пары.

Эффективная стратегия

Для каждого субъекта и pose bin:

сгруппировать изображения по событию и источнику;

выбрать до (K) качественных представителей каждой группы;

строить пары только между независимыми событиями;

ограничить число пар на одного субъекта;

балансировать subjects и pose bins.

Пример:

максимум 50 пар на человека;

максимум 10 пар на один pose bin;

максимум одна пара для одной комбинации событий.

Это уменьшает вычисления и не позволяет одному человеку с тысячей кадров доминировать в распределении.

Шаг 5. Калибровать каждую metric family отдельно

Необходимо хранить отдельные null distributions для:

landmark displacement;

dense normal displacement;

geodesic ratios;

curvature;

alpha_id;

symmetry;

UV LBP;

UV GLCM;

wrinkle graph;

color residual;

expression residual.

Пример ключа:

И статистики:

Шаг 6. Использовать эмпирический percentile, а не только z-score

Для асимметричного распределения robust z-score недостаточен.

Следует сохранять:

```
[
  p_{\text{emp}}(x)
=
\frac{
1 + \sum_i \mathbf{1}(X_i \geq x)
}{
n + 1
}.
]
```

Результат должен выглядеть так:

Шаг 7. Ввести жёсткий OOD gate

Калибровка неприменима, если анализируемая фотография находится вне диапазона датасета.

OOD должен проверять:

yaw/pitch/roll;

blur;

разрешение лица;

JPEG severity;

visibility coverage;

освещение;

expression magnitude;

detector confidence;

источник.

Если подходящих calibration samples мало:

а не экстраполяция z-score.

Шаг 8. Кластерная статистика вместо проверки каждой вершины

Для 35 709 вершин нельзя независимо проверять каждую вершину.
Правильнее:

получить signed residual;

стандартизировать по локальному calibration noise;

сформировать пространственно связанные кластеры;

оценить площадь, амплитуду и persistence;

сравнивать с максимальным кластером в null dataset.

Это уменьшает ложные срабатывания от единичных нестабильных вершин.

Шаг 9. Кэшировать калибровочные артефакты

Оптимальная структура:

В calibration_manifest.json:

dataset hash;

model hash;

code hash;

config hash;

feature schema version;

число subjects;

число independent events;

число пар по каждому bin.

Если hashes не изменились, калибровка не пересчитывается.

4. Наилучшая комбинированная реализация

Взять из app5

single inference;

identity-only mesh;

official landmark mapping;

renderer visibility;

combined visibility;

pose-bin canonical representation;

UV confidence;

validator;

hashes;

immutable Stage 1;

cautious statuses.

Взять из app4

downstream quality gate;

dense mesh zones;

signed normal displacement;

geodesic/spectral descriptors;

texture quality indicators;

baseline-return;

cross-bin corroboration;

локальные heatmaps.

Не переносить

Из app3 и app4 не следует переносить:

фиксированные Bayesian priors;

persona-era weighting;

silicone probabilities;

predetermined identity labels;

ручные likelihood;

texture floor без эмпирической калибровки;

сравнение невидимых зон.

5. Оптимальный порядок фильтрации шума

Финальный рейтинг

Компонент	app3	app4	app5
---	---:	---:	---:
Подавление геометрического шума	38	73	92
Подавление фотометрического шума	57	76	43
Калибровочный дизайн	50	75	87
Вычислительная эффективность	55	50	92
Защита от ложных выводов	30	62	97

Общая оценка	46/100	67/100	82/100
--------------	--------	--------	--------

Итог

Наибольшую эффективность даст app5 как основа, дополненная quality gate и dense/texture-модулями app4.

В текущем состоянии:

app5 — лучший для масштабируемой и воспроизводимой калибровки геометрии.

app4 — лучший источник дополнительных моделей шума, особенно для dense mesh и texture.

app3 — требует исправления Stage 1 до любой серьёзной интеграции калибровочного датасета.

Ключевая модернизация app5 — заставить Stage 2 реально потреблять сохранённые quality/confidence данные и добавить иерархическую калибровку dense mesh и texture.

продолжай анализ и сравни 3 версии по реализации выявления аномалий по хронологии, биологии, медицине
10:42 PM

Thought

Сравнение выявления аномалий по хронологии, биологии и медицине

Сначала принципиальное ограничение: по трём приложенным фотографиям 1999 года нельзя валидировать реальное выявление долгосрочных аномалий. В манифестах заявлены 20 изображений, но в архиве доступны только три результата. Поэтому ниже оценивается прежде всего **архитектура и логика кода**, а не доказанная медицинская точность.

Также нужно разделить три разных задачи:

Хронологическая аномалия — измерение резко изменилось относительно временного ряда.

Биологическая неправдоподобность — изменение плохо согласуется с эмпирически известной динамикой тканей.

Медицинская интерпретация — предполагаемая причина: возраст, отёк, стоматология, травма, операция, ботулинотерапия, филлер и т. п. Первая задача технически реализуема. Вторая требует внешнего биологического датасета. Третья не может считаться медицинской

диагностикой по фотографиям.

Сводный результат

Компонент	app3	app4	app5
---	---:	---:	---:
Полнота хронологического движка	54	83	80
Защита хронологии от технического шума	39	72	91
Охват биологических альтернатив	39	69	59
Научная обоснованность биологических правил	25	42	55
Медицинская диагностическая валидность	5	12	3
Безопасность медицинской интерпретации	20	45	95
Риск confirmation bias	Высокий	Средне-высокий	Низкий
Итоговая пригодность	32/100	60/100	72/100

app4 функционально шире, но app5 безопаснее и статистически чище. Низкая медицинская валидность app5 означает не дефект, а то, что система правильно не пытается изображать медицинский классификатор без медицинского датасета.

1. Выявление хронологических аномалий

Метрика	app3	app4	app5
---	---:	---:	---:
Проверка и сортировка дат	75	85	98

Сравнение внутри одинакового pose bin	70	90	98
Adjacent/ baseline/rolling comparison	75	92	92
Persistence и возврат к baseline	70	95	90
Контроль зависимости кадров одного события	40	65	75
Формальный change-point analysis	50	85	78
Conditioning по качеству изображения	45	88	55
Локализация изменения	55	95	85
Коррекция множественных проверок	20	45	35
Статус неопределённости	35	75	98
Среднее	53,5	81,5	80,4

app3

В app3 присутствуют:

временная сортировка;

соседние сравнения;

baseline;

pose bins;

поиск аномальных переходов;

Bayesian aggregation.

Но есть четыре фундаментальные проблемы.

Ошибочная visibility

Если скрытая сторона попала в ряд как якобы наблюдаемая, временная динамика может быть динамикой модельного prior, а не реальной поверхности.

Нет чистого identity-only ряда

Мимика может создать ложный скачок геометрии.

Заранее заданные аномалии

README и конфигурация содержат предварительно выделенные личности, эпохи и подозрительные события. Это повышает риск того, что временной ряд будет интерпретироваться под ожидаемый результат.

Категорическая классификация

Хронологическое отклонение слишком быстро превращается в:

different_person;

synthetic_substitution;

«подмена».

Это логический скачок: временной выброс не устанавливает причину.

app4

app4 имеет самый широкий хронологический движок:

adjacent comparison;

baseline comparison;

return-to-baseline;

rolling baseline;

same-bin chronology;

локальные события;

persistent changes;

reversions;

cross-bin corroboration;

mesh, landmarks, alpha_id и texture channels.

Сильная сторона: возврат к baseline

Это важный биологический тест.

Если признак:

резко изменился;

затем вернулся к прежнему значению,
то это снижает вероятность устойчивого структурного изменения и
повышает вероятность:

мимики;

отёка;

веса;

освещения;

кропа;

нестабильной реконструкции.

Недостаток

app4 содержит заранее заданные:

eras;

critical dates;

persona clues;

expected transitions.

Даже если они формально отделены от измерений, архитектура создаёт
риск выбора наиболее удобного объяснения после просмотра данных.

app5

app5 строит наиболее чистый геометрический временной ряд:

identity-only geometry;

same-pose-bin comparison;

pairwise visibility intersection;

median/MAD;

локальные descriptors;

persistence;

cautious statuses.

Но фактический chronology engine уже по набору функций, чем app4. Не полностью реализованы:

dense-mesh chronology;

quality-conditioned chronology;

texture chronology;

cross-bin structural confirmation;

кластерная коррекция множества точек.

Вердикт по хронологии

Лучший по широте: app4.

Лучший по чистоте входного сигнала: app5.

Наиболее рискованный: app3.

Для production следует использовать chronology app5 и перенести в него baseline-return и cross-bin corroboration из app4.

2. Выявление биологически необычных изменений

Метрика	app3	app4	app5
---	---	---	---
Identity/ expression separation	45	93	96
Учёт возрастных изменений	40	70	35
Учёт веса и мягких тканей	30	60	30
Учёт стоматологии и прикуса	25	55	25

Учёт косметических процедур	30	65	30
Анализ обратимости изменения	60	85	80
Межзональная согласованность	55	90	83
Учёт скорости изменения	55	85	85
Внешняя биологическая калибровка	20	35	30
Защита от биологических сверхвыводов	25	50	98
Среднее	38,5	68,8	59,2

Эта таблица оценивает полноту функций. По доказательной надёжности arr4 нужно понизить: большинство медицинско-биологических альтернатив реализовано как эвристики, а не как модели, обученные на клинических данных.

Что можно считать биологическим признаком

Система может проверить, что измерение:

изменилось слишком быстро;

устойчиво сохраняется после предполагаемой точки изменения;

наблюдается на независимых фотографиях;

сохраняется в разных ракурсах;

локализовано в одной анатомической области;

не объясняется expression-компонентом;

выходит за same-person calibration noise.

Но это ещё не означает, что изменение «биологически невозможно».

Корректная формулировка:

Изменение статистически нетипично относительно представленной same-person калибровки.

Некорректная формулировка:

Такое изменение биологически невозможно, следовательно, это другой человек.

app3: биологический анализ подменён гипотезами

app3 использует категории вроде:

возраст;

силикон;

синтетическая подмена;

другой человек.

Но нет внешней калибровки, показывающей, как реально изменяются соответствующие признаки при:

старении;

колебании веса;

стоматологическом лечении;

отёке;

травме;

косметических процедурах.

Следовательно, это скорее набор интерпретационных правил, чем биологическая модель.

Особенно опасно, что фиксированные вероятности создают впечатление количественной медицинской доказательности.

app4: самый широкий биологический differential

app4 рассматривает больше альтернатив:

aging;

soft-tissue dynamics;

weight-related changes;

expression;

baseline return;

texture smoothness;

«silicone proxy»;

persona transitions;

chronology of local zones.

Полезная часть

Полезными являются:

разделение identity/full mesh;

скорость изменения;

локальная согласованность;

persistence;

reversion;

сравнение костно-стабильных и мягкотканых областей.

Ненаучная часть

Названия вроде silicone_proxy создают медицинскую псевдоточность. По обычной фотографии нельзя надёжно установить материал или конкретную процедуру через простое отношение texture features.

Лучше переименовать:

в:

И не назначать медицинскую причину.

app5: наиболее осторожный, но неполный биологический слой

app5 имеет хорошую основу:

identity-only против full mesh;

скорость изменения;

persistent descriptors;

cross-date calibration;

status-based output.

Но chronology code использует термин biologically_improbable и

фиксированные условия вроде повышенного p95 z.

Проблема: в архиве нет биологической reference model, которая связывает z-score со скоростью изменения тканей.

Поэтому статус следует переименовать:

в:

или:

Это точно описывает измерение без неподтверждённого биологического вывода.

3. Медицинская интерпретация

Диагностическая валидность

Медицинский компонент	app3	app4	app5
---	---:	---:	---:
Клинически размеченный датасет	0	0	0
Подтверждённые диагнозы	0	0	0
Sensitivity/ specificity	0	0	0
Внешняя клиническая валидация	0	0	0
Blind medical review	0	0	0
Модель ботулинотерапии	0	5	0
Модель филлеров	0	10	0
Модель стоматологических изменений	0	5	0

Модель травмы/заболеваний	0	0	0
Корректная оценка причинности	5	10	30

Наличие файла или функции с названием silicone, aging или medical не является клинической моделью.

Что допустимо выводить

Допустимые результаты:

«обнаружено устойчивое локальное геометрическое отклонение»;

«изменение преимущественно находится в expression-sensitive зоне»;

«изменение обратимо»;

«результат может объясняться мягкими тканями»;

«недостаточно данных для различения возраста, веса, процедуры и артефакта»;

«требуется экспертная оценка».

Недопустимо автоматически утверждать:

«обнаружен ботокс»;

«обнаружен силикон»;

«сделана операция»;

«это заболевание»;

«это другой человек»;

«изменение биологически невозможно».

4. Какие альтернативы должна различать система

Правильный differential должен быть иерархическим.

Уровень 1. Техническое объяснение

Сначала исключаются:

другой yaw/pitch/roll;

невидимая сторона;

кроп;

blur;

JPEG;

свет;

цветовой баланс;

ретушь;

нестабильная реконструкция;

разные камеры;

кадры одной видеозаписи.

Если техническое объяснение достаточно, биологический анализ не запускается.

Уровень 2. Временное физиологическое объяснение

Проверяются:

отёк;

воспаление;

усталость;

обезвоживание;

временное изменение веса;

мимика;

мышечный тонус.

Типичный паттерн:

быстрое появление;

мягкотканная локализация;

последующее исчезновение;

отсутствие устойчивого identity-only изменения.

Уровень 3. Возраст и долговременная мягкотканная динамика

Ожидается:

постепенное изменение;

многолетняя временная шкала;

региональная согласованность;

отсутствие резкого однодневного скачка;

частичная зависимость от веса и качества кожи.

Но конкретные допустимые скорости должны определяться внешним возрастным датасетом.

Уровень 4. Стоматологическое или хирургическое вмешательство

Потенциальные зоны:

нижняя треть лица;

положение губ;

контур челюсти;

прикус;

подбородочная область;

нос;

орбитальная область.

Однако фотография не позволяет надёжно отличить процедуру от сочетания веса, мимики и модели.

Уровень 5. Травма или заболевание

Автоматическая система не должна ставить диагноз. Она может только отметить:

выраженную асимметрию;

резкое локальное изменение;

устойчивость;

отсутствие технического объяснения.

Дальнейшая интерпретация требует медицинских данных и профильного специалиста.

5. Правильная модель хронологической аномалии

Для каждой зоны (z) и даты (t) следует рассчитывать:

$$\begin{aligned} &[\\ &X_{\{z,t\}} \\ &= \\ &\operatorname{operatorname{median}} \\ &\left(\right. \\ &X_{\{z,t,1\}}, \ldots, X_{\{z,t,n\}} \\ &\left. \right), \\ &] \end{aligned}$$

где кадры одного события сначала агрегируются, а не считаются независимыми.

Далее:

$$\begin{aligned} &[\\ &R_{\{z,t\}} \\ &= \\ &X_{\{z,t\}} - \widehat{B}_{\{z,t\}}, \\ &] \end{aligned}$$

где $(\widehat{B}_{\{z,t\}})$ — ожидаемая траектория с учётом:

возраста;

pose bin;

качества;

источника;

времени между наблюдениями.

Аномалия должна учитывать пять компонентов:

$$\begin{aligned} &[\\ &A_{\{z,t\}} \\ &= \\ &S_{\{z,t\}} \\ &\cdot \\ &P_{\{z,t\}} \\ &\cdot \end{aligned}$$

$C_{\{z,t\}}$
 $\cdot$
 $V_{\{z,t\}}$
 $\cdot$
 $I_{\{z,t\}},$
 $]$
 где:

(S) — величина отклонения;

(P) — persistence;

(C) — пространственная coherence;

(V) — видимость и качество;

(I) — независимость источников.

6. Как отличать разные типы изменений

Наблюдаемый паттерн	Более вероятное объяснение	Необходимая проверка
Изменение только на одном фото	Артефакт	Другие источники той же даты
Исчезновение на следующей серии	Мимика, отёк, свет, кроп	Baseline return
Изменение только в full mesh	Expression/soft tissue	Identity-only comparison
Изменение есть в identity-only mesh	Reconstruction или устойчивая геометрия	Разные ракурсы и источники
Изменение только в UV texture	Свет, JPEG, ретушь, кожа	Photometric calibration
Изменение в UV и soft tissue	Физиология или процедура	Persistence и medical metadata
Изменение в нескольких соседних 3D-зонах	Более сильный геометрический сигнал	Dense cluster test
Изолированная одна вершина	Шум	Cluster correction
Резкий скачок и многолетняя устойчивость	Реальное устойчивое изменение возможно	Независимая биологическая проверка

Разные скачки в разных pose bins	Pose/model artifact	Cross-bin consistency
----------------------------------	---------------------	-----------------------

7. Что необходимо добавить каждой версии app3

Полностью исправить visibility.

Создать identity-only temporal series.

Удалить фиксированные медицинские likelihood.

Удалить different_person и synthetic_substitution.

Отделить наблюдение от интерпретации.

Ввести event/source aggregation.

Добавить robust change-point analysis.

Заменить медицинские labels нейтральными статусами.

app4

Убрать persona и era priors из inference.

Переименовать silicone/medical proxy.

Добавить renderer visibility.

Отделить direct measurements от heuristic features.

Калибровать каждую биологическую альтернативу отдельно.

Добавить множественную коррекцию.

Валидировать baseline return на независимых subjects.

Упростить fusion engine.

app5

Переименовать biologically_improbable.

Подключить quality metrics к chronology.

Добавить dense-mesh chronology.

Добавить baseline-return из app4.

Реализовать cross-bin corroboration.

Агрегировать кадры одного события.

Добавить source/camera effects.

Добавить cluster-level significance.

Ввести биологический reference layer.

Добавить texture/skin chronology.

Финальный вывод

app3

Хронологические функции есть, но выводы небезопасны. Система склонна превращать технические и временные выбросы в гипотезу о личности или медицинской причине.

app4

Самая широкая реализация хронологии и биологических альтернатив.

Особенно сильны persistence, baseline return, локальные зоны и dense geometry. Но медицинские proxy и prior-driven логика создают псевдоточность и confirmation bias.

app5

Наиболее надёжный фундамент. Лучше всего разделяет наблюдаемую геометрию, мимику, видимость и статистическую неопределённость. Но это пока не биологическая или медицинская модель: термины о «биологической невероятности» не обеспечены внешней клинической калибровкой.

Оптимальная версия:

Stage 1 и статистическая осторожность app5 + persistence/baseline-return/dense chronology app4 + отдельный внешний биологический датасет.

Без клинической разметки итоговый движок должен выявлять

лонгитюдные геометрические и текстурные аномалии, но не

диагностировать их медицинскую причину и не делать вывод о личности.

продолжай анализ и сравни 3 версии по реализации анализа полученных данных и формирования по ним выводов

10:49 PM

продолжай анализ и сравни 3 версии по реализации итогового отчета для широкой аудитории - условно статья языком журналиста-расследователя

10:53 PM

Сравнение трёх версий по качеству итогового отчёта для широкой аудитории

Здесь оценивается не точность 3DDFA_V3, а способность системы превратить технические результаты в понятную, проверяемую и редакционно безопасную статью в жанре журналистского расследования. Важное различие:

эффектная подача — понятный текст, графики, драматургия;

журналистская надёжность — отделение фактов от гипотез, источники, альтернативные объяснения, отсутствие неподтверждённых обвинений. app3 лучше выглядит как сенсационный черновик. app4 имеет наиболее развитую оболочку отчёта. app5 предоставляет наиболее надёжную доказательную основу, но пока хуже пишет для массового читателя.

Сводный рейтинг по 20 критериям

№	Критерий итогового отчёта	app3	app4	app5
---	---	---	---	---
1	Заголовок и вводный лид	75	88	65
2	Краткое резюме результатов	78	92	80
3	Хронологич еское повествова ние	70	95	82
4	Графики и визуальные материалы	70	96	85
5	Показ конкретных зон различий	60	96	88
6	Объяснение метода без перегрузки	68	88	72

7	Прослеживаемость каждого вывода	55	80	97
8	Provenance фотографий и результатов	50	72	98
9	Разделение факта и интерпретации	30	55	98
10	Представление неопределённости	35	72	99
11	Альтернативные объяснения	50	78	95
12	Отсутствие медицинских сверхвыводов	25	45	99
13	Отсутствие неподтверждённого вывода о личности	20	50	99
14	Объяснение visibility и скрытых зон	35	70	92
15	Честное описание ограничений выборки	45	70	95
16	Техническое приложение	55	82	98

17	Модульность для редактора	72	90	82
18	Защита от confirmation bias	20	45	98
19	Понятность массовому читателю	78	88	70
20	Готовность к публикации после редактуры	55	82	75
	Средний балл	52/100	77/100	88/100

Итоговые места

app5 — 88/100: лучшая доказательная основа, но нужен отдельный журналистский генератор.

app4 — 77/100: лучший визуально-редакционный каркас, но выводы нужно очистить от эвристик и предвзятых гипотез.

app3 — 52/100: читается ярко, но слишком легко превращает измерительный выброс в сенсационный вывод.

1. app3: эффектный, но опасный журналистский материал

Что сделано хорошо

app3 способен сформировать отчёт с понятными массовому читателю элементами:

краткое резюме;

хронология;

списки необычных наблюдений;

числовые оценки;

визуальные зоны;

объяснение возможных причин;

итоговый вердикт.

Текст можно быстро превратить в статью. Читатель получает ясную драматическую линию:

был стабильный период → появилась аномалия → система назначила гипотезу.

С точки зрения вовлечения аудитории это работает.

Главная проблема: вывод встроен в повествование заранее

В arr3 присутствуют заранее заданные:

предполагаемые личности;

подозрительные эпохи;

«аномальные» даты;

гипотезы о подмене;

медицинские или синтетические объяснения.

В результате отчёт рискует стать не расследованием, а подтверждением исходной версии.

Псевдоточная подача

Опасный шаблон:

Вероятность H2 «другой человек» составила 82%.

Читатель воспринимает это как статистически подтверждённую вероятность. Но число построено на:

фиксированном prior;

вручную назначенных likelihood;

ограниченной калибровке;

проблемной visibility.

Корректнее написать:

Комбинация выбранных метрик вышла за внутренние пороги системы. Эти пороги не проходили независимую биометрическую валидацию и не позволяют определить личность.

Рискованный язык

arr3 использует или поддерживает формулировки:

«синтетическая подмена»;

«другой человек»;

«силикон»;

«вероятна подмена».

Для широкой аудитории такие слова неизбежно становятся главным заголовком, хотя система не имеет достаточной доказательной базы.

Вердикт по app3

Хорошая машина для создания сенсационного текста, плохая основа для ответственной публикации.

Перед использованием необходимо:

удалить автоматический verdict;

убрать вероятности $H_0/H_1/H_2$;

удалить предварительные identity labels;

переписать выводы нейтральным языком;

отдельно показывать альтернативные объяснения;

добавить блок «что метод не может установить».

2. app4: лучшая оболочка журналистского расследования

Сильнейшая сторона — визуальная и повествовательная полнота

app4 лучше всех подготовлен к созданию большой статьи:

хронологические графики;

локальные карты различий;

mesh-зоны;

baseline-return;

adjacent comparisons;

рейтинги аномалий;

texture indicators;

Markdown/HTML-отчёты;

технические приложения;

подробные объяснения каждого модуля.

Из app4 проще всего собрать материал формата:

что мы проверили;

как менялись показатели;

какие даты выделяются;

где локализованы различия;

возвращаются ли параметры к прежнему уровню;

какие альтернативные объяснения существуют.

app4 лучше показывает конкретную деталь

Вместо общего:

Лица отличаются.

app4 способен сформировать более содержательный фрагмент:

Наибольший стандартизированный остаток сосредоточен в левой орбитальной и скуловой областях. Изменение повторяется в двух соседних датах, но не подтверждено в другом ракурсе.

Это гораздо полезнее для исследовательского текста.

Проблема №1: переизбыток метрик

app4 может показать читателю слишком много:

z-score;

ratios;

persona score;

silicone proxy;

chronology score;

curvature;

spectral distance;

geodesic distance;

Bayesian components;

quality modifiers.

Для массового читателя это создаёт не ясность, а эффект «цифровой стены»: большое количество чисел выглядит как доказательство, даже если метрики коррелируют и измеряют похожий шум.

В публичный отчёт должны попадать только:

3–5 сильнейших независимых наблюдений;

качество evidence;

альтернативные объяснения;

ограничения.

Остальное — в техническое приложение.

Проблема №2: медицинские и persona labels

Особенно рискованны:

silicone_proxy;

persona_score;

заранее заданные эпохи;

prior clues;

expected transition signatures.

В статье такие поля почти неизбежно превращаются в утверждения:

Алгоритм обнаружил признаки силиконовой маски.

Фактически это может быть всего лишь локальное изменение гладкости текстуры, вызванное:

светом;

blur;

JPEG;

ретушью;

макияжем;

разрешением;

особенностями UV-проекции.

Проблема №3: смешение прямых и косвенных свидетельств

В отчёте должны быть визуально разделены:

Прямое измерение

Среднее signed displacement в зоне составило X при Y общих видимых точках.

Производная статистика

Значение соответствует 98-му перцентилю внутренней same-person калибровки.

Интерпретационная гипотеза

Одно из возможных объяснений — изменение мягких тканей.
app4 местами объединяет эти уровни в один итоговый score.

Вердикт по app4

Лучший готовый каркас для большой визуальной статьи, но перед публикацией требуется жёсткая редакционная очистка.

Следует сохранить:

HTML/Markdown renderer;

графики;

локальные карты;

хронологию;

baseline-return;

технические приложения.

Следует удалить:

persona posterior;

silicone probability;

заранее заданные identity eras;

медицинские labels;

суммарный «вердикт».

3. app5: лучший источник доказательств, но ещё не журналистская статья

Главное преимущество — проверяемость

app5 лучше всех позволяет ответить на редакционные вопросы:

какая фотография использовалась;

совпадает ли её хэш;

какая модель использовалась;

какая версия кода;

какая конфигурация;

какие точки были реально видимы;

сколько точек участвовало в сравнении;

относится ли зона к исходным пикселям;

достаточно ли калибровочных данных;

какой статус разрешён.

Для журналистского расследования это критично. Редакция должна иметь возможность пройти от предложения в статье до конкретного измерения.

Лучшее разделение наблюдения и вывода

app5 использует осторожные статусы:

within_calibration_noise;

elevated_but_uncertain;

persistent_geometric_change;

expression_dominated;

insufficient_visibility;

insufficient_quality.

Это намного безопаснее, чем:

«другой человек»;

«маска»;

«силикон»;

«подмена».

Недостаток №1: язык слишком технический

Статус вроде:

подходит для технического отчёта, но не объясняет массовому читателю:

что именно изменилось;

насколько это заметно;

почему результат считается необычным;

какие есть альтернативные причины;

что нельзя заключить.

Нужен промежуточный narrative layer.

Недостаток №2: слабее визуальная драматургия

app5 сохраняет много полезных данных, но уступает app4 по:

готовым хронологическим графикам;

анатомическим картам;

сравнительным панелям;

baseline-return visualization;

редакционно оформленным объяснениям.

Недостаток №3: незавершённая texture-часть

Для широкой аудитории визуальные различия кожи, морщин и текстуры будут особенно заметны. Но Stage 2 app5 ещё маркирует texture как незавершённую часть.

Поэтому нельзя писать:

Система подтвердила изменение кожи.

Можно писать:

Геометрический анализ показал отклонение; независимый анализ текстуры в этой версии ещё не реализован.

Вердикт по app5

Лучший фактологический backend, но не лучший готовый автор статьи.

Ему нужен отчётный слой app4, работающий только с проверенными данными app5.

Два разных рейтинга

Готовность отчётной оболочки

Место	Версия	Балл
---:	---	---:
1	app4	88/100
2	app3	70/100
3	app5	72/100

app4 лучше всех умеет представить большой объём результатов.

Журналистская надёжность

Место	Версия	Балл
---:	---	---:
1	app5	96/100
2	app4	58/100
3	app3	28/100

app5 лучше всех защищает от неподтверждённых выводов.

Как должен выглядеть идеальный итоговый отчёт

1. Нейтральный заголовок

Плохо:

Алгоритм разоблачил подмену по фотографиям.

Хорошо:

Что показал 3D-анализ архивных фотографий — и чего он не может доказать

Допустимый расследовательский вариант:

Лицо в динамике: какие изменения обнаружила 3D-реконструкция архивных снимков

2. Лид

Мы сравнили датированные фотографии с помощью одной и той же модели 3D-реконструкции лица. Анализ выявил несколько локальных изменений, которые выходят за внутренний уровень шума системы. Однако фотографии различаются по ракурсу, качеству и источникам, а сам метод не позволяет устанавливать личность или медицинскую причину изменений.

Этот абзац одновременно:

сообщает результат;

удерживает интерес;

ограничивает вывод;

предупреждает о качестве evidence.

3. Блок «Что мы анализировали»

Необходимо указать:

число фотографий;

диапазон дат;

число независимых событий;

число источников;

распределение ракурсов;

сколько кадров исключено;

почему они исключены;

сколько результатов реально доступно для проверки.

Для текущего архива честная формулировка:

Манифесты трёх систем указывают на 20 обработанных фотографий, но в предоставленном архиве доступны полные результаты только для трёх дат. Поэтому аудит не подтверждает заявленную работу на всём наборе.

4. Блок «Как работал метод»

Объяснение массовому читателю:

Сначала система строила трёхмерную модель лица. Затем она отделяла поворот головы и мимику от предполагаемой постоянной геометрии. В сравнение включались только участки, которые камера действительно видела на обеих фотографиях. Полученные различия сопоставлялись с изменениями, наблюдаемыми на контрольных фотографиях одного и того же человека.

Обязательно добавить:

Канонизация не делает скрытую сторону лица наблюдаемой. Если камера не видела участок, модель могла лишь предсказать его форму.

5. Главные наблюдения

Каждое наблюдение должно иметь одинаковый формат.

Наблюдение

В левой орбитальной области найдено устойчивое локальное отклонение.

Доказательная основа

даты;

число независимых источников;

pose bins;

число общих видимых точек;

calibration percentile;

persistence;

качество изображений.

Альтернативные причины

ракурс;

мимика;

blur;

свет;

вес;

отёк;

стоматология;

процедура;

ошибка модели.

Ограничение

Результат не позволяет определить причину изменения или сделать вывод о личности.

6. Самые сильные контраргументы

Хорошая расследовательская статья должна показывать не только аргументы «за», но и наиболее сильные аргументы «против».

Например:

исходные кадры имеют разное разрешение;

несколько фотографий могут происходить из одного видео;

часть зон находится под большим углом;

UV-текстура содержит предсказанные пиксели;

нет внешней клинической калибровки;

полный набор из 20 результатов не приложен;

базовая 3D-реконструкция у всех разработчиков идентична.

7. Блок «Что система не установила»

Он должен присутствовать до заключения:

система не установила личность;

не обнаружила конкретный материал;

не диагностировала медицинскую процедуру;

не доказала отсутствие ретуши;

не подтвердила историческую дату файла;

не исключила все технические причины;

не прошла независимую биометрическую валидацию.

8. Заключение

Корректный итог:

Из трёх реализаций app5 лучше всего отделяет наблюдаемую поверхность от скрытых участков и наиболее осторожно формулирует результат. app4 предлагает более развитые карты и хронологические визуализации, но использует ряд эвристических показателей, которые нельзя представлять как медицинские или биометрические доказательства. app3 формирует наиболее категоричные выводы, хотя его расчёт видимости содержит существенную методологическую ошибку.

Формат доказательной карточки

Каждый публичный тезис должен автоматически сопровождаться внутренней карточкой:

Как объединить лучшие части

Источник истины — app5

Только app5 должен определять:

какие данные допустимы;

какие зоны видимы;

достаточно ли качества;

какой calibration status;

какие ограничения обязательны;

какие hashes соответствуют результату.

Визуальный и редакционный слой — app4

Из app4 следует взять:

HTML/Markdown renderer;

хронологические графики;

карты зон;

сравнение baseline/adjacent;

визуализацию persistence;

локальные heatmaps;

структуру технического приложения.

Из app3 можно взять только доступность языка

Полезны:

короткое резюме;

понятные заголовки;

последовательный рассказ;

объяснение без сложной математики.

Нельзя переносить:

автоматический вердикт;

вероятности личности;

сенсационные медицинские labels;

заранее заданные версии событий.

Финальная рекомендация

Лучший итоговый продукт должен генерировать одновременно два документа:

Публичная статья

1 500–3 000 слов;

понятный язык;

3–5 ключевых наблюдений;

хронология;

визуальные карты;

сильнейшие альтернативные объяснения;

отдельный блок ограничений;

отсутствие вывода о личности.

Техническое приложение

список файлов и hashes;

pose/quality/visibility;

все метрики;

calibration distributions;

критерии исключения;

версии кода и модели;

результаты validator;

методы статистической коррекции.

Оптимальная комбинация:

Доказательная база app5 + визуальная отчётность app4 + понятность языка app3, но без его категорических вердиктов.

В текущем виде app4 ближе всего к готовой журналистской оболочке, однако app5 — единственная версия, на основе которой эту оболочку можно сделать достаточно проверяемой и редакционно безопасной.

add
.zip

ты должен понимать что эти данные не взяты с головы – эта информация у меня уже не раз подтверждалась, поэтому эта информация может не вигурироваться в отчетах а может быть лично для того чтобы еще раз убеится в достоверности если эти данные опять совпадут в данном более точном анализе. поэтому не знаю как делать отдельным модулем или нет – но все это необходимо внедрить.

11:04 PM

Понимаю вашу логику: это не материал для обязательной публикации, а **накопленный внешний контекст и набор ранее подтверждавшихся гипотез**, которые нужно сохранить и проверить ещё раз уже более строгим методом. Выбрасывать эти данные нельзя.

После просмотра add.zip мой вывод однозначный:

Внедрять нужно отдельным приватным модулем подтверждения гипотез, полностью интегрированным с основной системой, но не влияющим на первичные измерения и калибровочный шум.

Это позволит одновременно:

использовать всю накопленную информацию;

проверять, совпадёт ли она с новым анализом;

не выводить её автоматически в публичный отчёт;

отличать реальное повторное подтверждение от результата, полученного потому, что гипотеза уже была встроена в модель.

Что находится в add.zip

Это уже не маленький набор примеров, а крупный массив:

1 912 основных фотографий;

период **1998–2026;**

девять ракурсных групп;

224 калибровочных изображения;

1 258 подобранных калибровочных пар;

1 654 хронологических события;

1 763 mesh chronology edges;

отдельные результаты для:

хронологии;

identity stress;

гипотез $H_0/H_1/H_2$;

change points;

$A \rightarrow B \rightarrow A$ возвратов;

«сингулярных» дат;

persona-групп;

noise reduction;

cross-bucket consensus.

Также приложен отдельный BioChrono-анализ 700 размеченных фотографий:

put: 327;

udmurt: 135;

vas: 238.

Эти данные нужно использовать, но необходимо правильно определить их роль.

Почему нельзя просто включить их в основной inference

В текущем архиве персональные предположения уже встроены в расчёт:

Также заданы априорные вероятности:

И заранее определены эпохи:

1999–2012 — оригинал;

2012–2021 — носитель В;

2021–2023 — переход;

2023–2026 — носитель С.

Если новый анализ использует эти labels непосредственно, совпадение уже не будет независимым подтверждением. Система частично получит ожидаемый ответ на входе.

Обнаруженная внутренняя несогласованность

В архиве одновременно присутствуют следующие результаты.

Основной финальный inference сообщает

transitions = 0;

impossible_changes = 0;

persona_count = 0;

critical_events = [];

доминирующая гипотеза во всех годах 1998–2026 — H0_SAME;

h0_contradictions пуст;

morphing_pairs пуст;

на заранее обозначенных границах эпох не найдено ни одного подтверждённого шага.

Другие слои того же архива сообщают

831 impossible_change_flags;

621 «сингулярную дату»;

десятки тысяч хронологических скачков;

persona-specific change points;

возможные «версии маски/лица»;

отдельные периоды PUT/UDMURT/VAS.

Это не значит, что ранее собранная информация неверна. Это означает, что сейчас смешаны:

технические выбросы;

исследовательские гипотезы;

persona-разметка;

финальные вероятностные выводы;

разные определения «невозможного изменения».

Новый модуль должен устранить эту неоднозначность.

Правильная архитектура: два независимых прохода

Контур А — слепой первичный анализ

Работает без доступа к:

PUT/UDMURT/VAS;

предполагаемым эпохам;

ожидаемым датам переходов;

версиям «носителей»;

prior clues;

медицинским объяснениям;

предыдущим итоговым score.

Он должен видеть только:

фотографию;

дату;

ракурс;

источник;

3D-геометрию;

visibility;

качество;

калибровочный датасет;

независимые технические метрики.

Результат:

Это основной источник истины.

Контур В — приватная проверка накопленных гипотез

Запускается **только после фиксации результатов контура А.**

Он получает:

результаты слепого прохода;

информацию из add.zip;

ранее определённые даты;

предполагаемые группы;

ожидаемые зоны;

ранее наблюдавшиеся признаки.

После этого он отвечает не на вопрос:

Кто изображён на фотографии?

А на более строгие вопросы:

Повторилась ли ранее отмеченная аномалия?

Совпала ли зона?

Совпало ли направление изменения?

Совпало ли временное окно?

Подтверждается ли изменение в другом ракурсе?

Есть ли независимые источники?

Присутствует ли такое же изменение в identity-only mesh?

Есть ли обратный переход?

Нашлись ли данные, противоречащие гипотезе?

Как должен называться модуль

Предлагаю:

или по-русски:

Структура:

Реестр гипотез

Каждое ранее полученное наблюдение нужно привести к формальной записи:

Так информация будет полностью внедрена, но не сможет незаметно подправлять первичный результат.

Четыре допустимых результата проверки

Для каждой гипотезы:

1. Повторно подтверждено

Условия:

слепой анализ самостоятельно обнаружил событие;

совпало временное окно;

совпали анатомические зоны;

сигнал устойчив;

подтверждён независимыми событиями;

виден минимум в двух подходящих ракурсах;

отсутствует достаточное техническое объяснение.

2. Частично подтверждено

Например:

дата совпала, но зона совпала только частично;

изменение есть только в одном pose bin;

найдено мало независимых источников;

geometry подтверждается, texture — нет.

3. Не подтверждено

Слепой анализ не нашёл ожидаемого эффекта при достаточном качестве данных.

4. Противоречит новым данным

Например:

ожидаемое изменение отсутствует;

показатели возвращаются к baseline;

изменение полностью объясняется мимикой;

на качественных фотографиях разных ракурсов геометрия стабильна.
Дополнительно:

если фотографий или видимости недостаточно.

Что из add.zip можно интегрировать напрямую
Можно использовать как технические данные

1 912 summary.json;

source fingerprints;

даты;

pose angles;

девять ракурсных buckets;

image quality;

readiness;

geometry metrics;

skin metrics с ограничениями;

mesh chronology;

calibration matching;

run provenance;

artifact hashes;

списки не сопоставленных фотографий.

Можно использовать только в приватном контуре

PUT/UDMURT/VAS labels;

persona ranges;

предполагаемые эпохи;

«носитель В/С»;

singular dates;

prior anomalies;

версии лица/маски;

ранее выделенные периоды;

surgery/mask/persona hypotheses;

identity_stress как производный исследовательский score.

Нельзя использовать как нейтральную калибровку шума

CSV с колонками:

не являются same-person noise calibration. Они уже содержат исследовательское разделение на группы и используются как discriminative reference.

Их правильный статус:

а не:

Проблемы данных, которые нужно учесть при импорте

1. Неполное calibration matching

Из 1 912 основных фотографий:

1 258 имеют калибровочные пары;

654 отмечены как unmatchable.

Для этих 654 фотографий нельзя использовать обычный calibration confidence. Нужен статус:

2. Частичные reference models

Аудит сообщает:

То есть полная reference-модель присутствует только для части ожидаемых групп.

3. Пропущенные метрики

Указано:

Это должно снижать evidence completeness.

4. Один из CSV повреждён

Файл для left_threequarter_deer начинается не с CSV-заголовка, а с текста:

Его нельзя импортировать как обычную ракурсную таблицу без предварительной очистки и проверки.

5. Конфликт определений impossible change

В одном месте:

В другом:

В новом модуле должны существовать разные названия:

raw_speed_flag;

quality_gated_speed_flag;

cross_pose_confirmed_speed_flag;

final_longitudinal_anomaly.

Нельзя называть все четыре уровня «биологически невозможным изменением».

Как вычислять совпадение с прежней информацией

Для гипотезы (H):

[
C(H)=
w_tT+
w_zZ+
w_dD+
w_pP+
w_sS+
w_qQ-
w_cC,
]

где:

(T) — совпадение временного окна;

(Z) — совпадение анатомических зон;

(D) — совпадение направления изменения;

(P) — подтверждение в разных pose bins;

(S) — независимость источников;

(Q) — качество и visibility;

(C) — сила противоречащих данных.

Но итоговый corroboration score не должен влиять обратно на:

mesh residual;

calibration percentile;

change-point location;

anomaly score слепого прохода.

Что попадёт в приватный отчёт

Что попадёт в публичный отчёт

По умолчанию — только слепой результат:

В определённом временном интервале система обнаружила устойчивое локальное геометрическое отклонение, повторившееся в нескольких независимых событиях. Анализ не устанавливает личность или причину изменения.

Персональные labels и прежние гипотезы не публикуются автоматически. Если вы решите раскрыть связь с прежними наблюдениями, это должно быть отдельной редакционной пометкой:

Этот период ранее выделялся автором исследования по другим признакам. Новая система анализировала фотографии без доступа к этой разметке и независимо отметила близкое временное окно.

Только такая последовательность позволяет честно сказать, что новый результат **снова совпал** с прежней информацией.

Итоговое решение

Да, все данные из add.zip нужно внедрить.

Но внедрение должно быть организовано так:

Так ваши предыдущие результаты:

не теряются;

остаются доступными для проверки;

не обязаны фигурировать в статье;

могут повторно подтвердиться;

могут частично подтвердиться;

могут быть опровергнуты;

не загрязняют калибровку и первичный анализ.

Это не ослабляет вашу гипотезу. Наоборот: если слепой более точный анализ без доступа к PUT/UDMURT/VAS и заранее заданным эпохам самостоятельно найдёт те же даты, зоны и направления изменений, такое совпадение будет значительно сильнее методологически, чем результат системы, которой эти категории уже были переданы на вход.